# Importation des fonctions


- Machine utilisée: Lenovo P92, CPU Intel Core i5-3470 3.2Ghz, RAM 8 Go - Windows 10 Pro – Puissance raisonnable mais insuffisante pour les calculs lourds.
- Importation des fonctions et du fichier de données
- On vérifie la bonne importation



## Standardisation des fichiers


- La variable target étant booléenne, on la transforme en numérique.
  - Création de la variable
     numérique trgt équivalente en
     0 et 1
  - Vérification que les deux variables correspondent bien

### Standardiser les fichiers



## Standardisation des fichiers

- Extraction de la variable y = tgrt à expliquer, du fichier général renommé
   X
- Suppression de la variable Product\_Info\_2 qui comporte des données non numérique
- Vérification de la forme définitive de X et y



## Random Forest

- On applique Random Forest et on mesure le ROC = 89,6%
- On étudie le ROC en fonction du nombre d'arbres. On limite à 100 arbres (hardware)
- On passe de 89.6% à près de 90,97%

### **Random Forest**

```
In [17]: model= RandomForestRegressor(n estimators=30,oob score=True,random state=42)
         model.fit(X,y)
Out[17]: RandomForestRegressor(bootstrap=True, criterion='mse', max depth=None,
                    max features='auto', max leaf nodes=None,
                    min impurity decrease=0.0, min impurity split=None,
                    min samples leaf=1, min samples split=2,
                    min weight fraction leaf=0.0, n estimators=30, n jobs=1,
                    oob_score=True, random_state=42, verbose=0, warm_start=False)
In [19]: y_oob=model.oob_prediction_
         s=roc auc score(y,y oob)
         print ("c-stat :",s)
         c-stat : 0.896506492098
In [21]: results = []
         n estimator options = [30,50,100]
         for trees in n estimator options:
             model=RandomForestRegressor(trees,oob score=True,random state=42)
             print(trees, "trees")
             roc=roc_auc_score(y,model.oob_prediction_)
             print("C-stat :",roc)
             results.append(roc)
             print("")
         30 trees
         C-stat : 0.896506492098
         50 trees
         C-stat : 0.903979076481
         100 trees
         C-stat : 0.90976384577
```


## Random Forest

- On fait varier la taille des feuilles de 1 à 7, mais avec un nombre d'arbres limité à 30 (hardware)
- On améliore le ROC de 89.6% à 90,7%

```
In [22]: #min samples leaf
         min samples leaf options = [1,2,3,4,5,6,7]
         for min samples in min samples leaf options:
             model=RandomForestRegressor(n estimators=30,oob score=True,
                                        random state=42,
                                        max features="auto",
                                        min samples leaf=min samples)
             model.fit(X,y)
             print(min samples, "min samples")
             roc=roc auc score(y,model.oob prediction)
             rocs[min samples] =[roc]
             print("C-stat: ",roc)
         1 min samples
         C-stat: 0.896506492098
         2 min samples
         C-stat: 0.90007083883
         3 min samples
         C-stat: 0.902170571064
         4 min samples
         C-stat: 0.90315544054
         5 min_samples
         C-stat: 0.905253127582
         6 min samples
         C-stat: 0.906000140976
         7 min samples
         C-stat: 0.907108910231
```

## **Random Forest**

- On visualise la courbe de progression du ROC en fonction du nombre de feuilles
- ROC serait donc meilleur avec à la fois un nombre d'arbres et de taille de feuilles plus important.



### **SVM**

- Préparation des données d'apprentissage et de test à partir du fichier X
- Application de l'algo SVM

### Séparer jeux d'apprentissage et jeux de tests

### **#TEST SVM SVC**

## **SVM**

- On applique la prédiction qui donne un score de 81,6%
- On renon ce à faire une analyse des paramètres sous GridSearch car le paramètre n\_jobs provoque un bug sous Windows répertorié comme non encore résolu

# Série d'algorithmes

 Nous importons tous les algorithmes de Scikit learn

### Grande série d'algorithmes

```
In [35]: def get_sklearn_algorithms(verbose = False):
             Explore all submodule of sklearn and fetch functions having a 'fit' attribute.
             Be careful : some functions are not models (ex : crossvalidators)
                 debug = print or not stuff on console
                 dict : { module : [ fit_functions] }
             from collections import defaultdict
             import importlib
            import sklearn
            algos = defaultdict(list)
            if verbose : print (dir(sklearn))
             for nom module in dir(sklearn):
                 if verbose : print (nom module)
                     to import = "sklearn.%s"%nom module
                     module = importlib.import module(to import)
                    for nom fonction in dir(module):
                       fonction = getattr(module, nom fonction)
                        if hasattr(fonction, "fit"):
                            if verbose : print (" nom algorithme = ", nom_fonction)
                            algos[nom module].append(fonction)
                 except Exception as e:
                    if verbose : print (e)
                 if verbose: print ("="*30)
             return algos
```

```
In [36]: algos = get_sklearn_algorithms()
for key in algos.keys():
    print ("\n==>",key)
    algos_= []
    for algo in algos[key]:
        classe_algo = str(algo)
        nom_algo = classe_algo[str(classe_algo).rfind(".")+1:str(classe_algo).rfind(""")]
        algos_.append(nom_algo)
    print (",".join(algos_))
```

# Série d'algorithmes

 On voit qu'il y a un grand nombre d'algos

```
classe_algo = str(algo)
  nom_algo = classe_algo[str(classe_algo).rfind(".")+1:str(classe_algo).rfind("'")]
  algos_.append(nom_algo)
print(",".join(algos_))
```

#### ===> ensemble

AdaBoostClassifier, AdaBoostRegressor, BaggingClassifier, BaggingRegressor, ExtraTreesClassifier, ExtraTreesRegressor, GradientBoostingClassifier, CradientBoostingRegressor, IsolationForest, RandomForestClassifier, RandomForestRegressor, RandomTreesEmbedding, VotingClassifier

#### ===> feature selection

GenericUnivariateSelect, RFE, RFECV, SelectFdr, SelectFpr, SelectFromModel, SelectFwe, SelectKBest, SelectPercentile, VarianceThreshold

### ===> gaussian process

GaussianProcess, GaussianProcessClassifier, GaussianProcessRegressor

#### ===> linear mode.

ARDRegression, BayesianRidge, ElasticNet, ElasticNetCV, HuberRegressor, Lars, LarsCV, Lasso, LassoCV, LassoLars, LassoLarsCV, LassoLarsCV, LassoLarsCV, LassoLarsCV, MultiTaskElasticNetCV, MultiTaskElasticNetCV, MultiTaskElasticNetCV, MultiTaskLassoCV, OrthogonalMatchingPursuit, OrthogonalMatchingPursuitCV, PassiveAggressiveClassifier, PassiveAggressiveRegressor, Perceptron, RANSACRegressor, RandomizedLasso, RandomizedLogisticRegression, Ridge, RidgeCV, RidgeClassifier, RidgeClassifierCV, SCDClassifier, SCDRegressor, TheilSenRegressor

```
===> model_selection
GridSearchCV, RandomizedSearchCV
```

#### ===> multiclas

 $Label Binarizer, One Vs One Classifier, One Vs Rest Classifier, Output Code Classifier, \_Constant Predictor$ 

### ===> neighbors

WeighborsClassifier, KNeighborsRegressor, KernelDensity, LSHForest, LocalOutlierFactor, NearestCentroid, NearestNeighbors, RadiusNeighborsClassifier, RadiusNeighborsRegressor

#### ===> preprocessin

Binarizer, FunctionTransformer, Imputer, KernelCenterer, LabelBinarizer, LabelEncoder, MaxAbsScaler, MinMaxScaler, MultiLabe lBinarizer, Normalizer, OneHotEncoder, PolynomialFeatures, QuantileTransformer, RobustScaler, StandardScaler

### ===> random projection

BaseRandomProjection, GaussianRandomProjection, SparseRandomProjection

#### ==> svm

LinearSVC, LinearSVR, NuSVC, NuSVR, OneClassSVM, SVC, SVR, pyd

# Série d'algorithmes

- On limite le test au 5 premiers (hardware)
- Les résultats de prévision s'échelonnent entre 33% et 83%

```
modeles_a_cescer.excend(algos[classe_de_models])
        for pointeur vers algo in modeles a tester:
                algorithme = pointeur vers algo()
                         = algorithme. doc
                          = doc[:min(doc.find(":"), 25)].strip()
                print (name)
                algorithme.fit(X_train, y_train)
                performance = algorithme.score(X test, y test)
                print (performance)
                if performance > best perf:
                    best algorithm = algorithme
                    best_perf = performance
                if 0<performance and performance<1:
                    performances[name] = [performance]
            except Exception as e:
               if "label" in str(e): print ("Algo de classification")
                                   : print (str(e)[:50])
            print ("="*30)
compteur=compteur-1
An AdaBoost classifier.
```

```
An AdaBoost classifier.

0.837697570182

An AdaBoost regressor.

0.333397616622

A Bagging classifier.

0.818235432885

A Bagging regressor.

0.448659766454

An extra-trees classifier

0.808150507195
```

# Série d'algorithmes - Conclusion

- On visualise les résultats de prévision suivant les différents algos
- Conclusion: Random Forest a le plus de potentiel sur ce jeu de données.

